论文思路汇报

IFCLora（Information-Flow Centrality）

~~**FlowLora/Topology-aware LoRA 拓扑感知/ GraphLoRA 图LoRA/ TopoLoRA(待选名)**~~

~~划线部分：要做增删~~

高亮部分：方便理解后续删除

> **引用部分：论文正文保留的部分**

简介：
通俗易懂介绍这篇论文的Idea

模型

↓机械可解释性（circuit trace电路追踪）

模型中的特征电路

↓隐式图构建（创新点）

隐式图（包含模型电路信息的）

↓图中心度算法（IFC创新点）

图中心度

↓分配算法（创新点）

秩分配

↓根据分配的rank训练（现有方法）

结果

分割线下面是论文必要章节↓

摘要

> 参数高效微调（Parameter-Efficient Fine-Tuning, PEFT）方法（如 LoRA）使得仅通过少量可训练参数即可对大型预训练模型进行有效适配。然而，现有方法通常将固定的低秩预算均匀分配到所有

> 层，忽略了 Transformer 内部各模块在信息处理中的功能差异。本文提出 **IFCLoRA**，一种拓扑感知的 LoRA 方法。受近年来机械可解释性研究的启发，我们利用电路追踪（circuit tracing）技术构建 Transformer 模型组件之间的**隐式交互图**，并提出一种新的指标 **信息流中心性（Information-Flow Centrality, IFC）**，通过多步信息传播刻画各模块在模型信息流中的重要程度。基于该指标，IFCLoRA 在保持整体参数预算不变的情况下，为处于关键信息路径上的模块分配更高的低秩适配能力。在多个推理与指令微调基准上的实验结果表明，在相同参数预算下，IFCLoRA 相比标准 LoRA 以及自适应方法（如 AdaLoRA）~~取得了更好的性能表现，验证了利用 Transformer 内部信息流拓扑进行参数分配是一种有效且具有可解释性的参数高效微调策略。~~

一.相关工作

1.1 PEFT（参数高效微调）/参数预算

1.1.1 2021 微软团队提出Lora微调

Hu 等 - 2022 - Lora low-rank adaptation of large lan- guage models.pdf

核心：从训练d*d $\mathcal{O}(d^2)$ **的参数量变成训练2*r* d** $\mathcal{O}(rd)$ **的训练量（减少了训练量）**

8*8变成8*2+2*8

原理图

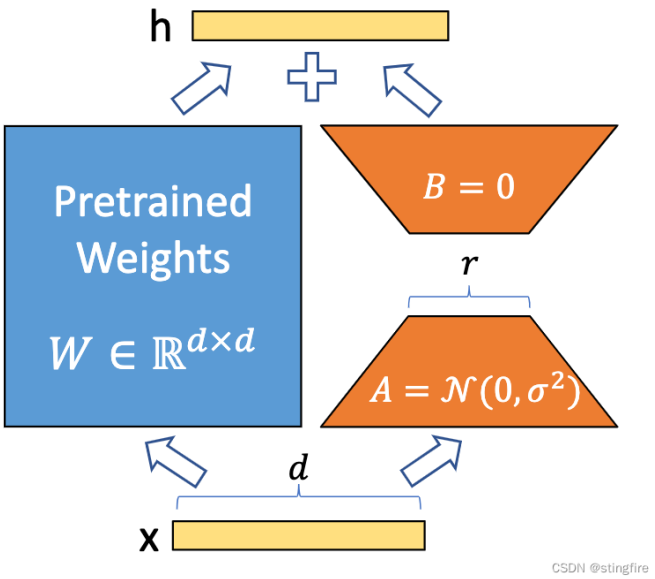

理论公式

d>>r

W0是d*d

B是d*r

A是r*d

BA就是d*d

$$h = W_0x + \Delta Wx = W_0x + BAx$$

1.1.2 2023 佐治亚理工学院提出了AdaLora

核心：**动态分配参数预算**和**基于敏感度的重要性评分**

奇异值分解（SVD）

$$\Delta W = BA = P\Lambda Q$$

将增量矩阵参数化为 $P\Lambda Q$ 的形式，并通过正则化惩罚项（正交惩罚）来近似 SVD 的效果

这是Lambda的秩就决定这个lora的重要性以此来分配

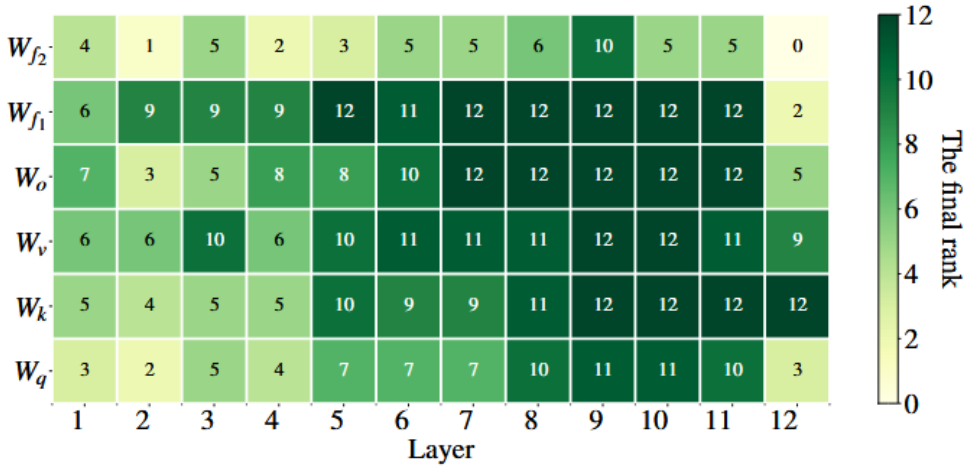

总结：**（把钱花在刀刃上）**

本来是2*R*d

现在是2*（r1+r2+...+rn）*d

R=r1+r2+...+rn

局限性：对所有层采用均匀分配，忽略了模块贡献的差异

1.2 Mechanistic（机械可解释性，提取隐式图的关键）

1.2.1 Claude团队提出Circuit Tracing

https://transformer-circuits.pub/2025/attribution-graphs/methods.html

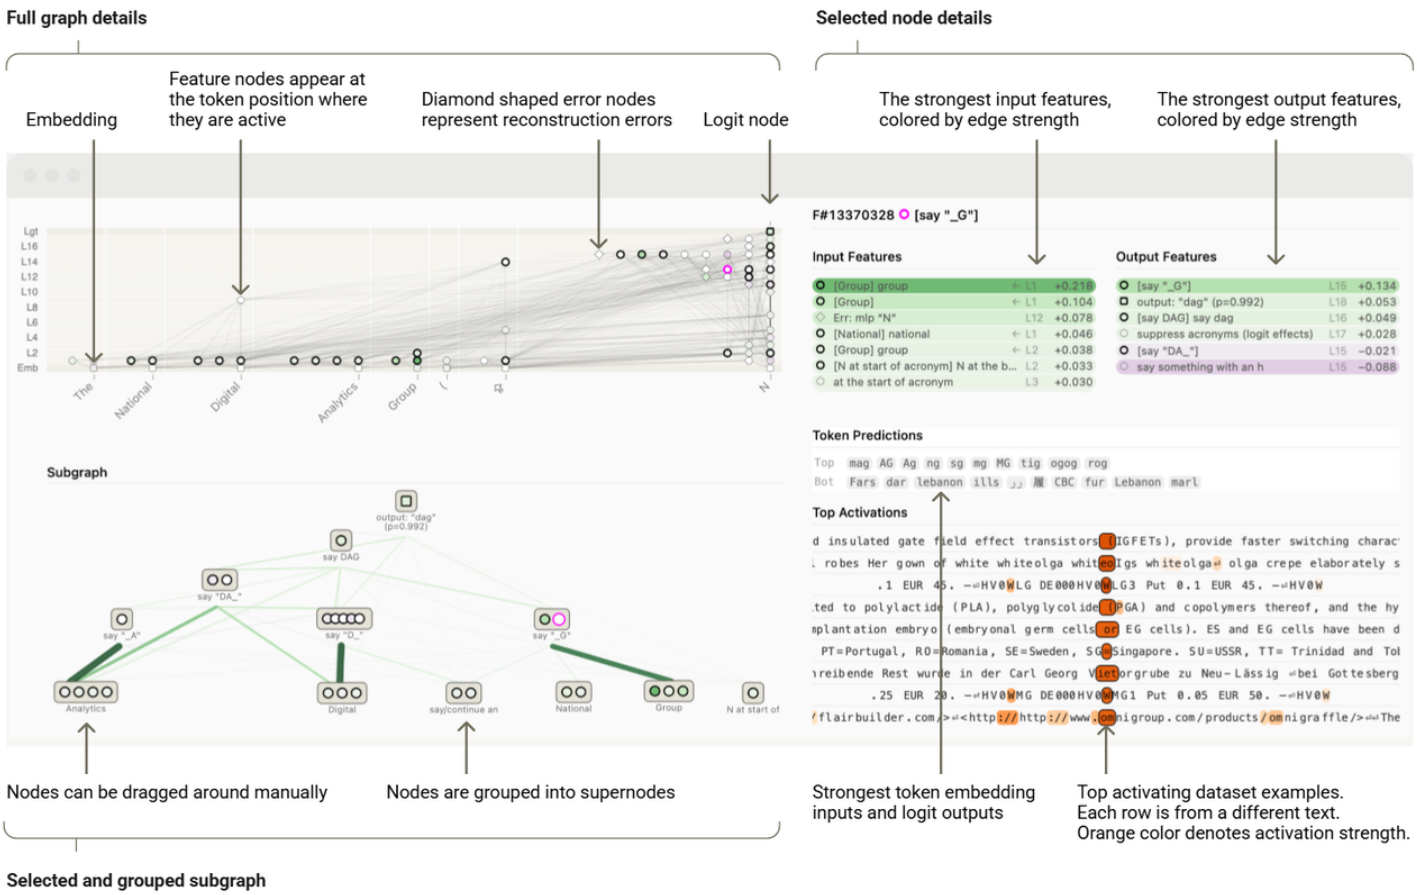

1.2.2 2025香港大学提出Circuit Lora

Towards Understanding Fine-Tuning Mechanisms of LLMs via Circuit Analysis.pdf

1.3图中心性算法

二.方法论

2.1 问题定义

2.1.1定义lora

2.1.2定义优化目标

> 传统：
>
> **Lora r_i=const（固定值）**
>
> AdaLoRA：
>
> **r_i = SVD分解()=** $P\Lambda Q = \Lambda$（的$rank$）
>
> IFCLora：

> r_i=IFC(Graph)

2.2 隐式图构建

> 我们将Transformer建模为一个隐式交互图，其中节点代表模型模块，边表示模块间的激活影响。
>
> 电路追踪器（Circuit Tracer）
>
> 利用机械可解释性（Mechanistic Interpretability）中的电路追踪器（Circuit Tracer），通过追踪激活流（Activation Flow）来构建有向图
>
> 我把数据集的数据输入给模型之后，模型的数据会做出改变，纪录A引起B的改变，有向图的方式

2.3 信息流中心Information Flow Centrality（原pagerank-only）

> Information Flow Centrality (IFC)
>
> $IFCi = \alpha \cdot Flowi + \beta \cdot GradSensi + \gamma \cdot PertImpi$
>
> $\alpha + \beta + \gamma = 1$

~~Pagerank算法：**一个网页的价值不仅取决于它被多少个网页链接，还取决于链接到它的网页本身的价值。**这就像是学术界的论文引用机制：被普通论文引用10次，可能不如被《Nature》或《Science》的顶级论文引用1次含金量高~~

~~寻找大模型网络中负责高级逻辑推理的“信息枢纽~~

~~通过Pagerank算法就可以算出特定模块的“含金量”~~

~~跑了一下MVP实验分配rank这一块已经完成，但是还没实际微调~~

~~下面这是only-Pagerank算法分配的权重(Qwen3-1.7)~~

rank_distribution.json

2.4 基于信息流的权重分配Centrality-based Rank Allocation

~~2.5 基于权重的PEFT（Lora）~~

~~这一部分可以加在2.4提一嘴~~

三.实验设计

3.1 实验设置Experimental Setup

3.1.1 模型

> **LLaMA3-8B（CircuitLora）**
>
> 大概40G显存就足够了
>
> ~~DeBERTa（AdaLora）180+M（参数量相差60~80倍）~~
>
> ~~RoBERTa-base（AdaLora）~~

3.1.2 数据集

> GSM8K（**CircuitLora**）
>
> GLUE
>
> SuperGLUE
>
> SQuAD
>
> ...（待新增）

3.1.3 Baselines

> LoRA（工业主流）
>
> AdaLoRA（老牌豪强）
>
> CircuitLoRA（新Sota）
>
> IFCLora（ours）

3.2 主实验Main Results

参考AdaLora列个表

Method	# Params	MNLI m/mm	SST-2 Acc	CoLA Mcc	QQP Acc/F1	QNLI Acc	RTE Acc	MRPC Acc	STS-B Corr	All Ave.
Full FT	184M	89.90/90.12	95.63	69.19	**92.40/89.80**	94.03	83.75	89.46	91.60	88.09
BitFit	0.1M	89.37/89.91	94.84	66.96	88.41/84.95	92.24	78.70	87.75	91.35	86.02
HAdapter	1.22M	90.13/90.17	95.53	68.64	91.91/89.27	94.11	84.48	89.95	91.48	88.12
PAdapter	1.18M	90.33/90.39	95.61	68.77	92.04/89.40	94.29	85.20	89.46	91.54	88.24
LoRA$_{r=8}$	1.33M	90.65/90.69	94.95	69.82	91.99/89.38	93.87	85.20	89.95	91.60	88.34
AdaLoRA	1.27M	**90.76/90.79**	**96.10**	**71.45**	**92.23/89.74**	**94.55**	**88.09**	**90.69**	**91.84**	**89.31**
HAdapter	0.61M	90.12/90.23	95.30	67.87	91.65/88.95	93.76	85.56	89.22	91.30	87.93
PAdapter	0.60M	90.15/90.28	95.53	69.48	91.62/88.86	93.98	84.12	89.22	91.52	88.04
HAdapter	0.31M	90.10/90.02	95.41	67.65	91.54/88.81	93.52	83.39	89.25	91.31	87.60
PAdapter	0.30M	89.89/90.06	94.72	69.06	91.40/88.62	93.87	84.48	89.71	91.38	87.90
LoRA$_{r=2}$	0.33M	90.30/90.38	94.95	68.71	91.61/88.91	94.03	85.56	89.71	**91.68**	88.15
AdaLoRA	0.32M	**90.66/90.70**	**95.80**	**70.04**	**91.78/89.16**	**94.49**	**87.36**	**90.44**	91.63	**88.86**

3.3 权重分配分析Rank Allocation Analysis

不同层分配的 rank

> 分析发现：
> 中后段的层获得的rank更高

3.4 隐式图构建分析Graph Construction Analysis

比较不同的图中心性指标。

> Pagerank
> Degree
>
> ...
> **IFC(ours)**

3.5 消融实验Ablation Study

> w/o graph
>
> w/o flow
>
> w/o gradient
>
> ~~反转rank（第一层4第二层16→第一层16第二层4）~~
>
> **full model**

3.6 效率分析Efficiency Analysis

Method	Trainable Params	GPU Memory	score	Time
Full FT	100%	100%	80	1.0x
LoRA	0.80%			
AdaLoRA	0.80%			
Ours	0.80%	5%	89	10%

分析参数量，显存，跑分，时间